

Hausarbeit im Seminar „Personennamen“

im Masterstudium Germanistik

Quantitative Onomastik

-

Eine Monte-Carlo-Studie zur Clusterstabilität und parametrischen
Robustheit regionaler Berufsamen

Vorgelegt von

Marc Wunderlich

Inhaltsverzeichnis

Einleitung.....	1
1. Theoretische Grundlagen der Berufsnamenforschung	2
1.1 Ursprung von Familiennamen.....	2
1.2 Funktionen von Familiennamen und Entwicklung von Berufsnamen.....	3
1.3 Regionale Namensverteilungen	5
Teil A: Modell und Simulation	5
2. Historisch-regionale Namensverteilungen	5
2.1 Norddeutschland.....	6
2.2 Ostdeutschland	6
2.3 Westdeutschland.....	7
2.4 Bayern.....	7
2.5 Schwaben.....	7
2.6 Rheinland	7
2.7 Parametrisierung regionaler Namensprofile.....	8
3. Mathematisches Modell.....	8
3.1 Regionale Namensverteilungen als Wahrscheinlichkeitsvektoren	8
3.2 Die Dirichlet-Verteilung als Modell für regionale Namensverteilungen.....	9
3.3 Hierarchisches Modell regionaler und lokaler Verteilungen	10
3.4 Interpretation der Modellparameter	11
4. Simulation regionaler Namensverteilungen.....	11
4.1 Mikrosimulation auf Orts- und Regionalebene	11
4.2 Monte-Carlo-Ansatz.....	12
5. Stabilitäts- und Sensitivitätsanalyse.....	13
5.1 Variation der Orts-Homogenität β	13
5.2 Variation der Namensdimension κ	15
5.3 Interaktion $\beta \times \kappa$	17
Teil B: Quantitative Analyse.....	18
6. Deskriptive Analyse	18
6.1 Relative Häufigkeiten	19
6.2 Regionale Unterschiede: Jensen-Shannon-Divergenz und Gini-Koeffizient	21
7. Unsupervised Learning: Clusteranalyse.....	23
7.1 K-Means-Clustering	23
7.2 Bestimmung der optimalen Clusterzahl	26
7.3 Vergleich mit simulierten Regionen	27
7.4 DBSCAN.....	28
8. Supervised Learning: SVM-Klassifikation	31
8.1 Methodik und Modellansatz	31
8.2 Training und Klassifikationsergebnisse.....	32
8.3 Evaluation und Fehleranalyse	34
9. Diskussion methodischer Grenzen.....	35
9.1 Modellannahmen und Realität	35
9.2 Sensitivität gegenüber α -Parametern.....	36
9.3 Onomastische Interpretation	36

Fazit.....	37
Anhang.....	39
<i>A Tabellen</i>	<i>39</i>
A.1 Historisch-regionale Namensverteilungen.....	39
<i>B Python-Code für Reduzierbarkeit</i>	<i>40</i>
Literaturverzeichnis	40

Einleitung

Im Deutschland des 21. Jahrhunderts besitzt nahezu jede Person einen Vor- und Nachnamen, wobei Familiennamen als historisch gewachsene Marker sozialer und regionaler Zugehörigkeit bis in das Mittelalter zurückreichen. Eine zentrale Gruppe bilden dabei die Berufsnamen (z.B. *Schmidt*, *Wagner*, *Müller*), die ursprünglich konkrete Tätigkeiten bezeichneten, ihre semantische Transparenz jedoch im Zug der Vererbbarkeit weitgehend verloren haben. Nichtsdestoweniger tragen sie weiterhin Spuren historischer Wirtschaftsstrukturen und regionaler Spezialisierungen.

Es ist davon auszugehen, dass Berufsnamen ursprünglich einer räumlichen Konzentration folgten, indem bestimmte Namen in Regionen mit entsprechender ökonomischer Prägung gehäuft auftraten. Die Binnenmigration führte jedoch zu einer partiellen Auflösung dieser Zusammenhänge. Die heutige Verteilung von Familiennamen ist daher das Ergebnis von historischer Verankerung und räumlicher Mobilität. Vor diesem Hintergrund stellt sich die Frage, inwiefern sich dennoch systematische regionale Unterschiede in den Namensverteilungen nachweisen lassen.

Ein zentrales Problem für quantitative Analysen stellt jedoch die eingeschränkte Verfügbarkeit geeigneter Daten dar. Dienste wie Geogen basieren auf Telefonbuchdaten, die aus datenschutzrechtlichen Gründen nicht frei zugänglich sind. Eine umfassende empirische Analyse regionaler Namensverteilungen ist somit nur sehr eingeschränkt möglich. Daher wird in der vorliegenden Arbeit ein semiempirischer Ansatz gewählt: Anstelle realer Daten wird eine synthetische, jedoch strukturtreue Namensverteilung mithilfe probabilistischer Modelle erzeugt. Konkret wird eine Mikrostruktur simuliert, die einem abstrahierten „Telefonbuch“ entspricht und somit die Grundlage für die weiterführende Analyse bildet.

Diese Arbeit geht davon aus, dass sich auch unter diesen vereinfachten Modellannahmen Strukturmuster identifizieren lassen. Daraus folgen zwei Arbeitsthese: Erstens sind regionale Unterschiede in Namensverteilungen auch unter vereinfachten Modellannahmen statistisch identifizierbar und zeigen sich konsistent über verschiedene Analyseverfahren hinweg. Zweitens führen Ähnlichkeiten in den Namensverteilungen dazu, dass sich Regionen zu Clustern verdichten, die strukturelle Ähnlichkeit zu historisch gewachsenen Namensräumen aufweisen können.

Die onomastische Forschung ist bislang überwiegend qualitativ geprägt und fokussiert vor allem auf etymologische und sprachhistorische Fragestellungen. Quantitative

Ansätze stellen demgegenüber eine vergleichsweise junge, jedoch zunehmend bedeutende Erweiterung dar. Parallel dazu haben sich in Computerlinguistik und Digital Humanities datengetriebene Verfahren etabliert, die auch auf Namen angewendet werden können. Studien zur Klassifikation von Namen nach ethnischer Zugehörigkeit (vgl. Ambekar et al. 2009) oder zur Analyse großskaliger Namensdatensätze (vgl. Monasterio 2017) zeigen, dass Namen als strukturierte Daten modelliert und mit statistischen Methoden untersucht werden können.

Die Arbeit gliedert sich in zwei Teile. In Teil A werden zunächst die theoretischen Grundlagen sowie die Modellierung regionaler Namensverteilungen entwickelt. Auf Basis literaturgestützter Annahmen werden Wahrscheinlichkeitsvektoren definiert und mithilfe der Dirichlet-Verteilung in konkrete Daten überführt. In Teil B werden die erzeugten Daten durch Anwendung von Clustering- und Klassifikationsverfahren sowie einer Untersuchung von Diversität und Konzentration analysiert. Abschließend werden die Ergebnisse interpretiert und die methodischen Grenzen des Ansatzes reflektiert.

Ziel der Arbeit ist es, zu zeigen, dass probabilistische und datengetriebene Verfahren einen substantiellen Beitrag zur onomastischen Forschung leisten können, da sie es ermöglichen, einen großen Datensatz an Namensverteilungen in sichtbare Muster zu überführen.

1. Theoretische Grundlagen der Berufsnamenforschung

Kapitel 1 legt die theoretischen Grundlagen der vorliegenden Arbeit, indem zentrale Konzepte der Onomastik und insbesondere der Berufsnamen systematisch dargestellt werden. Es wird hier gezeigt, wie sich Familiennamen historisch entwickelt haben, welche Funktionen sie erfüllen und weshalb sie klare regionale Verteilungen aufweisen. Die theoretischen Überlegungen bilden die Basis für die im folgenden Kapitel entwickelte Modellierung regionaler Namensverteilungen.

1.1 Ursprung von Familiennamen

Ein spätes Phänomen der europäischen Sprachgeschichte sind Familiennamen. Während in frühmittelalterlichen Gesellschaften ein einzelner Rufname zur Identifikation ausreichte, führte das Bevölkerungswachstum im Hoch- und Spätmittelalter zu einer steigenden Notwendigkeit eindeutiger Personenbezeichnungen. Infolgedessen mussten

ergänzende Benennungsstrategien gebildet werden, die zunächst in Form von Beinamen auftraten.

Als ursprünglich nicht vererbbares Element waren Beinamen individuell und situationsgebunden auf eine Person zugeschnitten. Sie konnten sich im Laufe eines Lebens verändern und dienten vorrangig der Unterscheidung von Personen mit identischen Rufnamen (vgl. NÜBLING 2015, 145f.). Erst im Zuge sozialer und administrativer Verdichtung, die besonders zwischen dem 13. und 16. Jahrhundert auftrat, setzte sich eine Erbllichkeit dieser Bezeichnungen durch, wodurch es zur Ausbildung stabiler Familiennamen kam (vgl. ebd., 146).

Die Etablierung von Familiennamen ist nicht allein funktional zu erklären. Neben der Notwendigkeit der Identifikation spielten auch soziale und institutionelle Faktoren eine Rolle, etwa die zunehmende Bedeutung von Besitzverhältnissen, administrativer Kontrolle sowie die Markierung familiärer Zugehörigkeit (vgl. ebd., 147). Die ursprünglich variablen Beinamen wurden somit fixiert und als erbliches System institutionalisiert.

1.2 Funktionen von Familiennamen und Entwicklung von Berufsamen

Mit der Etablierung der Erbllichkeit von Familiennamen bildeten sich verschiedene Typen von Benennungsmustern heraus. In der onomastischen Forschung wird dabei typischerweise zwischen fünf Hauptklassen unterschieden: Patronyme, Berufsamen, Wohnstättennamen, Herkunftsnamen und Übernamen (vgl. NÜBLING 2015, 149).

Patronyme beziehen sich auf den Rufnamen eines Vorfahren, meist des Vaters, und stellen eine besonders produktive Kategorie dar. Allerdings führt die große Vielfalt möglicher Rufnamen zu einer starken Diversifikation, sodass die Häufigkeit einzelner Patronyme gering ist (vgl. ebd.). Wichtig zu erwähnen sind die sog. „sekundären Patronyme“, die der Profession des Vaters folgen, somit nicht zu den Berufsamen gezählt werden. Metronyme, also die Benennung nach der Mutter kommen vor, sind aber weitaus seltener anzutreffen als Patronyme (vgl. ebd.).

Berufsamen hingegen gehen auf konkrete Tätigkeiten zurück und spiegeln sozioökonomische Verhältnisse vormoderner Gesellschaften wider. Namen wie *Schmidt*, *Müller* oder *Wagner* bezeichneten ursprünglich den ausgeübten Beruf einer Person. Mit der Vererbung der Namen verlor diese Bezeichnung allerdings ihre direkte referenzielle

Funktion (vgl. ebd. 13f.). Die ursprüngliche semantische Motivation bleibt jedoch etymologisch rekonstruierbar.

Charakteristisch für Berufsnamen ist zudem ihre hohe Variabilität. Diese folgt einerseits aus dialektalen Unterschieden (z. B. *Bäcker* / *Becker*, *Metzger* / *Fleischer*), andererseits aus Wortbildungsprozessen wie Komposita (*Kupferschmied*, *Gerstenbauer*). Zudem existieren indirekte Berufsnamen, die sich nicht auf die Profession selbst, sondern nur auf das Herstellungsprodukt, wie *Sauerbrod*, beziehen (Nübling 2015, 151).

Wohnstättennamen dienen der Lokalisierung von Personen anhand ihres unmittelbaren Umfelds und beziehen sich auf topologische und siedlungsbezogene Merkmale wie Landschafts- und Flurbezeichnungen (vgl. ebd.).

Herkunftsnamen wurden häufig „Zugezogenen von den Einheimischen gegeben und benennen sie nach Herkunftsort, -region oder -land. Sie transportieren dabei Toponyme, und diese oft in ihren früheren Schreibungen“ (Nübling 2015, 154). Auch hier tritt eine große Variation auf. Allein für Schwaben treten mindestens zehn Formen auf: *Schwab*, *Schwabe*, *Schwaab*, *Schwob*, *Schwabl*, *Schwäble*, *Schwaabe*, *Schwöble*, *Schwäbl*, *Schwoob* (Nübling 2015, 155).

Übernamen bildeten sich aus charakterisierenden Appellativa und Adjektiven, die Besonderheiten einer Person hervorheben sollten. Diese müssen allerdings nicht immer positiv gemeint sein, sondern können auch ironisch oder spöttisch gemeint sein. Die meisten Übernamen beziehen sich auf körperliche Charakteristika wie Haare, Kopfform oder Körpergröße (vgl. ebd.). Doch auch geistige Eigenschaften können betont werden. So verweist etwa der Nachname *Wunderlich* auf eine als auffällig, seltsam oder außergewöhnlich wahrgenommene Person.¹

Grundlegend für alle Namenklassen ist die funktionale Rolle im Sprachsystem. Namen zeichnen sich durch ihre Monoreferenz aus, also durch die eindeutige Zuordnung zu einem spezifischen Referenzobjekt. Ihre zentrale Funktion besteht darin, Objekte zu identifizieren und, im Fall von Familiennamen, auch zu individualisieren. Im Gegensatz zu appellativen Ausdrücken besitzen sie keine semantische Beschreibung, sondern fungieren als direkte Referenzmittel (vgl. ebd., 17-20).

¹ Vgl.

https://www.namenforschung.net/dfd/woerterbuch/liste/?L=0&tx_dfd_names%5Bname%5D=409&tx_dfd_names%5BcurrentSelectedFacets%5D=&tx_dfd_names%5Bquery%5D=WUnderlich&tx_dfd_names%5Boffset%5D=&tx_dfd_names%5Baction%5D=show&tx_dfd_names%5Bcontroller%5D=Names&cHash=702b8bb2633a34407060dfdc832cb1e2 (Zugriff 31.03.2026)

1.3 Regionale Namensverteilungen

Ein zentrales Merkmal von Familiennamen ist ihre ungleichmäßige räumliche Verteilung. Namen sind nicht zufällig über den Raum verteilt, sondern zeigen regionale Konzentrationen. Diese können auf historische, wirtschaftliche und sprachliche Faktoren zurückgeführt werden.

Untersuchungen zeigen, dass bestimmte Namen in Regionen gehäuft auftreten, in denen die basierenden Benennungsmotive historisch besonders relevant waren. Gleichzeitig spiegeln Familiennamen sprachgeographische Strukturen wider, etwa dialektale Unterschiede, die sich in der Variation von Nachnamen manifestieren. Somit stellt die Familiennamengeographie ein wichtiges Bindeglied zwischen Linguistik, Geschichte und Sozialwissenschaft dar (vgl. Nübling 2015, 156).

Ein Beispiel für derartige regionale Unterschiede zeigt die unterschiedliche Verteilung von Namenstypen. Wohnstättennamen treten häufig in bestimmten geographischen Räumen, insbesondere in topographisch stark gegliederten Regionen, häufiger auf als in anderen. Gleichzeitig lassen sich bis heute regionale Schwerpunkte bestimmter Namen nachvollziehen (vgl. ebd. 2015, 152).

Diese Gebundenheit an eine bestimmte Region macht Familiennamen zu einer besonders geeigneten Grundlage für quantitative Analysen. Sie ermöglichen es, historische Strukturen indirekt zu rekonstruieren und räumliche Muster zu verdeutlichen. Gerade Berufsamen sind hier für besonders relevant, da sie eng mit vormodernen Wirtschaftsstrukturen einher gehen.

Vor diesem Hintergrund lassen sich Familiennamen als ein sprachliches Korpus verstehen, das systematisch analysiert werden kann. Ihre Verteilung entspricht dabei keinem zufälligem Muster, sondern ist das Ergebnis historischer Prozesse, die sich mithilfe quantitativer Methoden modellieren und untersuchen lassen,

Teil A: Modell und Simulation

2. Historisch-regionale Namensverteilungen

Aufgrund datenschutzrechtlicher Einschränkungen steht kein umfassender Datensatz realer Personendaten zur Verfügung. Daher wird ein synthetischer Datensatz erzeugt, der reale Namensverteilungen approximiert. Grundlage bildet ein probabilistisches Modell,

in dem Nachnamen als Wahrscheinlichkeitsvektoren parametrisiert und mittels Dirichlet-Verteilung simuliert werden (vgl. Kap. 3)

Die Analyse erfolgt auf Basis von sechs Makroregionen (Nord, Ost, West, Rheinland, Bayern, Schwaben), die jeweils durch mehrere reale Städte repräsentiert werden. Die Einwohnerzahlen werden aus Effizienzgründen nicht real übernommen, sondern über eine logarithmische Normalverteilung im Bereich von 5.000 bis 15.000 simuliert. Die eindeutige Zuordnung von Personen zu Orten ermöglicht eine spätere räumliche Analyse und Clusterbildung.

Die folgende Parametrisierung beruht auf literaturgestützten Annahmen zur regionalen Verteilung von Familiennamen. Ziel ist es, typische Namensprofile zu modellieren, die bekannte sprach- und wirtschaftshistorische Strukturen widerspiegeln.

steht für diese Arbeit kein umfassender Datensatz realer Personendaten zur Verfügung. Infolgedessen wird ein synthetischer Datensatz erzeugt, der versucht, reale Nachnamensverteilungen möglichst realitätsnah zu approximieren.

2.1 Norddeutschland

Die Annahme eines eigenständigen norddeutschen Namensprofils ist familiennamegeographisch gut begründet. Besonders entlang der Benrather Linie zeigen sich klare Unterschiede, etwa zwischen *Schröder* im Norden und *Schneider* im Süden (vgl. Nübling 2023, 388). Gleichzeitig sind Berufsamen im Norden insgesamt weniger dominant als in anderen Regionen; stattdessen treten häufiger Patronyme auf (vgl. ebd., 387).

2.2 Ostdeutschland

Der ostdeutsche Raum weist ein eigenständiges onomastisches Profil mit slawischen und patronymischen Einflüssen auf. Morphologische Merkmale wie die Suffixe *-asch*, *-usch* oder *-schke* verweisen auf diese sprachhistorischen Grundlagen.

Zugleich zeigen einzelne Berufsamen eine deutliche regionale Konzentration. Besonders *Richter* sowie *Schulz* sind im ostdeutschen Raum stark vertreten (vgl. Nübling 2023, 621; Ebner 2015, 586). Beide Namen werden daher als dominante bzw. moderat dominante Parameter gewählt.

2.3 Westdeutschland

Der westdeutsche Raum ist durch eine hohe Dichte klassischer Berufsnamen geprägt, insbesondere im Kontext historischer Gewerbestrukturen entlang des Rheins (vgl. EBNER 2015, 659f.). Namen wie *Schneider* und *Weber* weisen hier erhöhte Frequenzen auf, was mit der Bedeutung des Textilhandwerks zusammenhängt.

Schneider fungiert dabei als süd- und westdeutsches Pendant zu *Schröder* und wird als dominanter, *Weber* als moderat dominanter Name modelliert.

2.4 Bayern

Für den bayrischen Raum ist *Bauer* ein charakteristischer Familienname, der auf die historisch agrarische Prägung der Region verweist. Ergänzend tritt *Mayer* als häufig vorkommender Name auf, der mit Besitz- und Verwaltungsfunktionen verbunden ist (vgl. NÜBLING 2023, 359). Die Kombination dieser Namen bildet eine vergleichsweise stabile und weniger stark diversifizierte Namensstruktur ab.

2.5 Schwaben

Besonders auffällig für diese Region ist das Auftreten von Namen aus dem Holzverarbeitenden Gewerbe. So treten Namen wie *Zimmermann*, *Böttcher* oder *Wagner* konzentrierter auf als in anderen Regionen (Nübling 2023, 485). Ergänzend treten auch Namen aus dem Bäckerhandwerk auf.

2.6 Rheinland

Das Rheinland ist durch eine Mischung aus handwerklich geprägten Berufsnamen und regionaltypischen Varianten gekennzeichnet. Besonders Namen wie *Becker* und *Schäfer* weisen hier erhöhte Frequenzen auf, was mit der historischen Bedeutung entsprechender Gewerbe zusammenhängt (vgl. KUNZE 2001, 202f.). Diese Namen werden daher als dominante Parameter gewählt, um das regionale Profil adäquat abzubilden.

2.7 Parametrisierung regionaler Namensprofile

Die Parametrisierung orientiert sich an relativen Häufigkeiten, wie sie etwa im Digitalen Familienwörterbuch Deutschland dokumentiert sind. Die Grundverteilung der Namen wird normiert und anschließend skaliert, um statistische Stabilität zu gewährleisten.

Für jede Region werden ein stark und ein moderat dominanter Name definiert, deren Gewichtung durch Multiplikation mit entsprechenden Faktoren erfolgt. Die konkrete Ausgestaltung der Parameter ist in **Tab. 2** dargestellt.

3. Mathematisches Modell

Da keine realen Bevölkerungsdaten zur Verfügung liegen, wurde sich entschieden, über eine Simulation die Realität bestmöglich nachzuahmen. Dafür wird im Folgenden auf die Regionale Namensverteilungen in Form von Wahrscheinlichkeitsverteilungen eingegangen, die wiederum in einer multinomialen Dirichlet-Verteilung zu einer Bevölkerungsstatistik entwickelt werden.

3.1 Regionale Namensverteilungen als Wahrscheinlichkeitsvektoren

Ausgehend von der Annahme, dass Berufsnamen innerhalb einer Region unterschiedlich häufig auftreten, kann eine jede Region durch Wahrscheinlichkeitsvektoren beschrieben werden. Sei κ die Anzahl der betrachteten Nachnamen, so definieren wir für jede Region einen Vektor

$$\boldsymbol{\theta} = (\theta_1, \theta_2, \dots, \theta_\kappa) \quad (3.1)$$

mit den Eigenschaften

$$\sum_{i=1}^{\kappa} \theta_i = 1 \quad \text{und} \quad \theta_i \geq 0 \quad (3.2)$$

Der Eintrag (θ_i) beschreibt dabei die Wahrscheinlichkeit, dass ein zufällig ausgewählter Individuumsträger in der jeweiligen Region den Nachnamen i trägt. Da Wahrscheinlichkeiten nicht negativ sein können, folgt daraus die Bedingung der Nichtnegativität. Zudem stellt die Normierungsbedingung sicher, dass es sich um eine gültige Wahrscheinlichkeitsverteilung handelt.

Die entstehenden Vektoren spiegeln die in Kapitel 2 qualitativ beschriebenen Befunde wider: Dominante Namen entsprechen hohen θ_i -Werten, seltene Namen entsprechend kleineren Anteilen.

Durch diese Wahrscheinlichkeitsvektoren kann das onomastische Problem in ein statistisches überführt werden: Anstelle diskreter Namenslisten arbeiten wir mit kontinuierlichen Wahrscheinlichkeitsvektoren, die sich mathematisch modellieren lassen.

3.2 Die Dirichlet-Verteilung als Modell für regionale Namensverteilungen

Für die Modellung solcher Wahrscheinlichkeitsvektoren bietet sich die Dirichlet-Verteilung an. Sie ist eine multivariate Wahrscheinlichkeitsverteilung über dem k -dimensionalen Simplex, also genau dem Raum aller möglichen Wahrscheinlichkeitsvektoren $\boldsymbol{\theta}$.

Ein Zufallsvektor ($\boldsymbol{\theta} = (\theta_1, \dots, \theta_\kappa)$) folgt einer Dirichlet-Verteilung mit dem Parametervektor ($\boldsymbol{\alpha} = (\alpha_1, \dots, \alpha_\kappa)$), wenn seine Dichte gegeben ist, durch (BISHOP 2006, 76f.):

$$\text{Dir}(\boldsymbol{\theta} \mid \boldsymbol{\alpha}) = \frac{1}{B(\boldsymbol{\alpha})} \prod_{i=1}^{\kappa} \theta_i^{\alpha_i-1} \quad (3.3)$$

mit der Normierungskonstante

$$B(\boldsymbol{\alpha}) = \frac{\prod_{i=1}^{\kappa} \Gamma(\alpha_i)}{\Gamma(\sum_{i=1}^{\kappa} \alpha_i)} \quad (3.4)$$

Dabei bezeichnet Γ die Gammafunktion. Die Parameter ($\alpha_i > 0$) bestimmen dabei die Form der Verteilung. Sie können als eine Art „Pseudozählung“ interpretiert werden: Je größer α_i , desto stärker wird der entsprechende Name im Erwartungswert gewichtet. Der Erwartungswert ergibt sich zu

$$E[\theta_i] = \frac{\alpha_i}{\sum_{j=1}^k \alpha_j} \quad (3.5)$$

Damit bietet die Dirichlet-Verteilung eine direkte Möglichkeit, die in Kapitel 2 aufgestellten Dominanzstrukturen mathematisch abzubilden. Dominante Namen erhalten somit höhere α_i -Werte, seltene Namen umgekehrt kleinere Werte.

3.3 Hierarchisches Modell regionaler und lokaler Verteilungen

Um sowohl regionale als auch lokale Variation abzubilden, wird ein hierarchisches Modell verwendet. Hier wird für jede Region r ein regionsspezifischer Wahrscheinlichkeitsvektor gezogen:

$$\boldsymbol{\theta}^{(r)} \sim \text{Dir}(\boldsymbol{\alpha}^{(r)}) \quad (3.6)$$

Dieser Vektor beschreibt dabei die durchschnittliche Namensverteilung der Region. Auf lokaler Ebene, zum Beispiel einzelne Städte, können daraus wiederum konkrete Beobachtungen generiert werden. Sei N die Anzahl der Individuen in einer Stadt, so gilt:

$$\mathbf{x}^{(r)} \sim \text{Multinomial}(N, \boldsymbol{\theta}^{(r)}) \quad (3.7)$$

Dabei ist $(\mathbf{x}^{(r)} = (x_1, \dots, x_k))$ ein Vektor absoluter Häufigkeiten der Namen. Optional kann das Modell erweitert werden, indem eine zusätzliche Hierarchieebene hinzugefügt wird, etwa durch den globalen Parameter $\boldsymbol{\beta}$, aus dem die regionalen Parameter selbst generiert werden können:

$$\boldsymbol{\alpha}^{(r)} \sim \text{Dir}(\boldsymbol{\beta}) \quad (3.8)$$

Dies erlaubt es, gemeinsame Strukturen zwischen den Regionen zu simulieren und gleichzeitig regionale Abweichung zu ermöglichen.

3.4 Interpretation der Modellparameter

Die Parameter, die im Modell verwendet werden, besitzen eine klare inhaltliche Interpretation und ermöglichen es, die obig beschriebenen Strukturen der Onomastik formal abzubilden.

Von großer Zentralität ist der Parametervektor ($\alpha = (\alpha_1, \dots, \alpha_k)$) der Dirichlet-Verteilung. Die einzelnen Komponenten α_i bilden gewichtete Zählungen, die die relative Bedeutung eines Nachnamens innerhalb einer Region bestimmen. Ein höherer Wert von α_i führt dazu, dass der entsprechende Name im Erwartungswert häufiger auftritt, während kleine Werte seltene Namen repräsentieren.

Die Summe aller Parameter ($\sum_{i=1}^k \alpha_i$) die Konzentration der Verteilung. Größere Summenwerte implizieren stabile, wenig streuende Wahrscheinlichkeitsvektoren θ , während kleine Werte eine höhere Varianz und damit stärkere Schwankungen erzeugen. Vereinfacht ausgedrückt bedeutet dies, dass größere α_i klarer abgegrenzte Strukturen erzeugen und andersherum.

Der aus der Dirichlet-Verteilung gezogene Vektor θ stellt die konkrete Namensverteilung einer Region dar. Er ist dabei eine latente Größe, die die „wahre“ Verteilung beschreibt, während die beobachteten Daten lediglich eine Realisierung darstellen.

Die anschließende Multinomialverteilung modelliert die konkrete Ziehung von Namen innerhalb einer Population. Dabei wird die kontinuierliche Wahrscheinlichkeitsstruktur in diskrete Beobachtungsdaten überführt und somit bildet sie den Übergang von der theoretischen Verteilung zur empirischen Datenstruktur.

Das Modell erlaubt eine klare Trennung zwischen strukturellen und zufälligen Effekten: Die Parameter α kodieren systematische, historisch und sprachgeographisch begründete Unterschiede zwischen Regionen, während die Dirichlet- und Multinomialverteilungen die stochastische Variation innerhalb dieser Strukturen erfassen. Damit bietet dieses Modell eine geeignete Verbindung zwischen onomastischer Theorie und probabilistischer Modellierung.

4. Simulation regionaler Namensverteilungen

4.1 Mikrosimulation auf Orts- und Regionalebene

Ziel der Simulation ist es, eine Verteilung von Personen auf bundesdeutschem Gebiet zu erzeugen, die eine kleinere Bevölkerungsstatistik deutscher Berufsamen sein könnte.

Den sechs gewählten Regionen wurden jeweils acht Städte zugeordnet, in denen diese Personen wohnen. Auf eine realitätsgetreue Übernahme der Einwohnerstärke wurde jedoch aus mehreren Gründen verzichtet: Erstens würde die genaue Wiedergabe der Einwohnerzahl einen Mehrwert an Arbeit bedeuten, der in diesem Rahmen nicht zu leisten ist. Zweitens würden derart große Zahlen im Millionenbereich bedeuten, dass die Varianz gegen null strebt. Demnach würde dadurch die Aussagekraft der Ergebnisse leiden. Ebenfalls würde bei der folgenden Monte-Carlo-Untersuchung bei einem Datenumfang von 84 Millionen und 50 Durchläufen 4,2 Milliarden Datenpunkte generiert werden, was eine signifikante Zunahme der Rechenleistung erforderte. Daher wurde sich dafür entschieden, dass die Einwohnerzahlen der 48 Städte durch eine logarithmische Normalverteilung in einem Intervall von 5.000 bis 15.000 Einwohnern erzeugt werden. Anhand des in Kapitel 3 beschriebenen Modells werden so synthetische Namensdaten erzeugt. Zunächst wird für jede Region eine regionale Namensverteilung θ_{region} durch die Dirichlet-Verteilung gezogen. In einem zweiten Schritt wird eine lokale Verteilung θ_{city} generiert, die um das regionale Profil streut.

Auf Grundlage dieser lokalen Verteilung werden die Nachnamen für eine vorgegebene Anzahl an Personen vergeben. Dies geschieht über die in Kapitel 2 definierten α -Parameter, die die Namensverteilung für eine bestimmte Region berücksichtigen. So entsteht ein Mikrodatenbestand, der einerseits regionale Unterschiede als auch lokale Variationen enthält. Der Vorteil dieses Vorgehens liegt darin, dass so komplexe Bevölkerungsstrukturen kontrolliert erzeugt werden können, ohne dass datenschutzrechtliche Bedenken auftreten oder Namensdaten durch das Crawlen unzähliger Telefonbücher extrahiert werden müssten.

4.2 Monte-Carlo-Ansatz

Das Monte-Carlo-Verfahren sorgt für eine Sicherheit der Ergebnisse, indem es die Simulation mehrfach wiederholt. Dafür werden im Rahmen eines Monte-Carlo-Ansatzes unabhängige Datensätze generiert, die dann genutzt werden können, um Mittelwerte und Streuungsmaße zu berechnen (BISHOP 2006, 538).

Durch die Wiederholungen können so zufallsbedingte Schwankungen reduziert und zuverlässige Aussagen über die Struktur der simulierten Namensräume getroffen werden. Speziell ermöglicht dieser Ansatz, die Sensitivität des Modells gegenüber den zufälligen Variationen systematisch zu untersuchen. Dabei ist es ein Abwägen, wie viele Durchläufe

durchgeführt werden sollten. Werden zu wenige gewählt, ist eine höhere statistische Fluktuation der Werte denkbar (MURPHY 2012, 815); werden wiederum zu viele Durchläufe gewählt, steigt die Rechenzeit bald ins unermessliche. Im Rahmen dieser Arbeit wurde sich dafür entschieden, mit 50 Durchläufen zu arbeiten. Diese resultierenden Datensätze bilden die Grundlage für die folgenden quantitativen Analysen, in denen sowohl deskriptive Statistiken als auch maschinelle Lernverfahren zur Anwendung kommen.

5. Stabilitäts- und Sensitivitätsanalyse

5.1 Variation der Orts-Homogenität β

Für eine Untersuchung der Orts-Homogenität β wurde der Parameter β systematisch variiert. β steuert in dem verwendeten hierarchischen Dirichlet-Modell die Streuung der lokalen Ortsverteilungen um das jeweilige regionale Profil. Dabei führen niedrigere Werte von β zu einer höheren Variation zwischen den Orten innerhalb einer Region, während mit steigenden Werten von β eine stärkere Angleichung an regionale Muster beobachtet wird.

In der vorliegenden Analyse wurden drei Werte von β (20, 50 und 100) betrachtet. Für jede Parametrisierung wurden durch eine Monte-Carlo-Analyse 50 Simulationen durchgeführt, um eine Stabilität der Ergebnisse zu gewährleisten. Anschließend wurden die resultierenden Namensverteilungen mittels *k-Means*-Clustering analysiert. Dabei diente als Bewertungsmaß für die Clusterqualität der Silhouettenkoeffizient, während für die Quantifizierung der Unterschiede zwischen den regionalen Verteilungen die Jensen-Shannon-Divergenz herangezogen wurde.

Die Ergebnisse der Untersuchung indizieren einen klaren Zusammenhang zwischen dem Homogenitätsparameter β und der Clusterstruktur. Mit steigendem β steigt auch der mittlere Silhouettenkoeffizient signifikant an (vgl. **Abb. 1**). Während bei $\beta = 20$ lediglich ein Wert von ungefähr 0.20 erreicht wird, erhöht sich dieser bei $\beta = 50$ auf rund 0.32 und bei $\beta = 100$ auf circa 0.46. Dies deutet darauf hin, dass die Cluster mit steigender Homogenität zunehmend besser separiert werden. Währenddessen verändert sich die Standardabweichung über alle Werte nur unwesentlich, was eine hohe Stabilität der Ergebnisse über die einzelnen Simulationen hinweg impliziert.

Nichtsdestoweniger wird bei der Jensen-Shannon-Divergenz ein gegenläufiger Effekt deutlich. Mit wachsendem β nimmt die mittlere Divergenz zwischen den Regionen ab,

von etwa 0.204 bei $\beta = 20$ über 0.136 bei $\beta = 50$ bis letztlich zu 0.108 bei $\beta = 100$. Ebenfalls hier sind die Standardabweichungen insignifikant gering, was die Robustheit des Trends betont. Die abnehmende Divergenz deutet darauf hin, dass die stärkere Homogenisierung innerhalb der Regionen zu einer teilweisen Angleichung der regionalen Profile führt.

Einfluss von β auf die Clusterqualität und regionale Divergenz




Abb. 1: Abhängigkeit des Silhouettenkoeffizienten und der Jensen-Shannon-Divergenz vom Homogenitätsparameter β .

Abb. 1 zeigt den Einfluss des Homogenitätsparameters β sowohl auf die Clusterqualität als auch auf die regionale Divergenz. Während der Silhouettenkoeffizient mit steigendem β ebenfalls stark monoton ansteigt, nimmt die Jensen-Shannon-Divergenz gleichzeitig ab. Dies zeigt, dass eine stärkere Homogenisierung innerhalb der Regionen sowohl die interne Kohärenz erhöht als auch die Unterschiede zwischen den Regionen reduziert. Es lässt sich somit konstatieren, dass der Parameter β als zentraler Steuerungsmechanismus fungiert, der die Balance zwischen intra-regionaler Heterogenität und inter-regionaler Differenzierung bestimmt.

Die Analyse zeigt, dass insbesondere mittlere bis höhere Werte von β geeignet sind, um stabile und interpretierbare Clusterstrukturen zu erzeugen, ohne dass die Variation zu stark verloren geht. Somit stellt β einen entscheidenden Parameter für die Simulation realistischer und klar strukturierter Namensräume dar.

5.2 Variation der Namensdimension κ

In einem zweiten Schritt wird untersucht, wie sich die Namensdimension κ auf die Struktur der simulierten Namensräume auswirkt. Während β die Homogenität der Ortsprofile innerhalb einer Region steuert, beziffert κ die Anzahl in der Simulation verwendeten Nachnamen. Mit einer steigenden Anzahl an Nachnamen erhöht sich somit die Komplexität des Merkmalraums, da mehr Nachnamen in die Simulation eingeht und die einzelnen Profile dadurch stärker ausdifferenziert werden können.

Dabei wurden drei unterschiedliche Werte für κ (15, 30, 45) betrachtet und für jede dieser Kombinationen wurden 25 Monte-Carlo-Simulationen durchgeführt. Anschließend wurden die resultierenden Ortsprofile unter Zuhilfenahme des k-Means-Algorithmus in sechs Cluster aufgeteilt. Diese gebildeten Cluster wurden schließlich mit dem Silhouettenkoeffizient auf ihre Qualität überprüft. Zusätzlich wurde die mittlere Jensen-Shannon-Divergenz zwischen den einzelnen Aggregaten berechnet, um so die Differenzen zwischen den Regionen unabhängig von der Clusterbildung zu untersuchen. Anhand der Ergebnisse kann ein eindeutiger Trend beobachtet werden: Wie aus Abb. X ersichtlich ist, sinkt die Clusterqualität mit wachsender Namensdimension nahezu monoton. Gleichzeitig zeigt auch die Jensen-Shannon-Divergenz einen Rückgang, was eine zunehmende Angleichung der regionalen Verteilungen impliziert.

Bei $\kappa = 15$ tritt noch ein gemittelter Wert von 0.266 auf, bei $\kappa = 30$ fällt er auf 0.109 und bei $\kappa = 45$ liegt er nur noch bei etwa 0.060. Es wird daraus ersichtlich, dass die Clusterstruktur mit zunehmendem κ immer diffuser wird. Da gleichzeitig ebenso die Standardabweichungen abnehmen, kann darauf geschlossen werden, dass der Effekt nicht durch einzelne Ausreißer zustande kommt, sondern das Produkt einer Entwicklung ist.

Bei Betrachtung der Jensen-Shannon-Divergenz ergibt sich ein ähnliches Bild. Die Mittelwerte sinken auch hier mit wachsender Namensdimension. Tritt bei $\kappa = 15$ noch ein Wert von 0.075 auf, sinkt er bei $\kappa = 30$ auf 0.055 und bei $\kappa = 45$ auf 0.053. Das zeigt klar eine Abnahme der regionalen Differenzierbarkeit durch die Zunahme der Anzahl der Nachnamen. Inhaltlich kann dies dadurch erklärt werden, dass die zusätzlichen

Nachnamen nicht dieselbe regionale Spezifität in der Simulation besitzen wie die ursprünglich ausgewählten dominanten Namen, sondern die zusätzlichen Namen die Verteilung stärker auffüllen und die Differenzen der Regionen somit glätten.

Einfluss der Namensdimension κ auf die Clusterqualität




Abb. 2: Abhängigkeit des Silhouettenkoeffizienten und der Jensen-Shannon-Divergenz von der Namensdimension κ .

Dennoch verdeutlicht die Variation von κ einen zentralen Zusammenhang zwischen Merkmalsraum und Clustern. Kleinere Namensdimensionen heben regionale Unterschiede deutlicher hervor und begünstigen die klarere Abgrenzung von Clustern. Andersherum erhöht eine größere Anzahl von Namen zwar die Realitätsnähe und Komplexität der Simulation, erschwert aber die eindeutige Trennung der Regionen im Merkmalsraum. Folglich kann subsummiert werden, dass je mehr Nachnamen berücksichtigt werden, desto stärker überlagern sich die regionalen Profile und desto schwächer werden die modellierten Kerninstanzen. Die Namensdimension κ stellt damit einen zweiten zentralen Sensitivitätsparameter dar, der maßgeblich für die Balance zwischen analytischer Trennschärfe und inhaltlicher Realitätsnähe verantwortlich ist.

5.3 Interaktion $\beta \times \kappa$

Die durchgeführten Sensitivitätsanalysen verdeutlichen, dass sowohl der Homogenitätsparameter β als auch die Namensdimension κ einen signifikanten Einfluss auf die Struktur der simulierten Namensräume haben. Während hohe Werte von β die Clusterbildung deutlich stabilisieren, führt eine zunehmende Namensdimension zu einer Abschwächung der Trennschärfe.




Abb. 3: Auswirkungen von $\beta \times \kappa$ auf die Clusterqualität. Es ist zu sehen, dass mit steigendem β der Silhouettenkoeffizient steigt, mit steigendem κ fällt.

Die kombinierte Betrachtung beider Parameter verdeutlicht, dass sich die besten Ergebnisse bei einer moderaten Namensdimension und einer hinreichend hohen Homogenität ergeben. Insgesamt bestätigen die Analysen, dass die Modellparameter nicht unabhängig voneinander wirken, sondern in ihrer Kombination die Qualität der resultierenden Clusterstrukturen bestimmen.




Abb. 4: Auswirkungen von $\beta \times \kappa$ auf die regionale Divergenz. Es ist zu sehen, dass mit steigendem β die Divergenz abnimmt, und somit abgegrenztere Muster entstehen.

Die bisherigen Analysen fokussierten primär aggregierte Maßzahlen wie den Silhouettenkoeffizienten und die Jensen-Shannon-Divergenz, um so die Qualität der Simulation bewerten zu können. Allerdings erlauben diese Verfahren nur begrenzte Aussagen über die konkrete räumliche Ausprägung der simulierten Instanzen.

Im folgenden Teil wird sich daher der quantitativen Analyse gewidmet. Ziel ist dabei die simulierten Namensverteilungen sowie die daraus resultierenden Strukturen geographisch zu visualisieren und im regionalen Kontext zu interpretieren. Erst dadurch lässt sich feststellen, inwiefern die simulierten Daten tatsächlich räumlich kohärente Muster bilden wie sich diese zu den zugrunde gelegten Makroregionen verhalten.

Teil B: Quantitative Analyse

6. Deskriptive Analyse

Mithilfe der in Kap. 4 beschriebenen Verfahren konnte eine Bevölkerungsstatistik erzeugt werden, die 388570 Personen erfasst. Diesen Personen werden jeweils eine Region, ein Ort, ein Bundesland, Längen- und Breitengrad sowie ein Nachname zugeordnet. Anschließend wurden die Mikrodaten zu einer Makroliste aggregiert, die erfasst, wie viele Personen eines bestimmten Nachnamens in welcher Stadt leben. Weitergehend

wurde einerseits eine Liste erstellt, die das gleiche für die einzelnen Bundesländer und Regionen erfassen.

6.1 Relative Häufigkeiten

Für eine erste quantitative Einschätzung der simulierten Namensverteilungen werden die jeweils dominanten Nachnamen pro Region und Bundesland betrachtet. Ein Nachname ist dann dominant, wenn er innerhalb einer Region oder eines Bundeslandes den höchsten relativen Anteil aufweist.

Abb. 5 zeigt dabei die Verteilung der dominanten Nachnamen für die simulierten Makroregionen. Dabei treten erwartungskonforme Muster zutage. Der Name Schröder dominiert im Norden, Bauer in Bayern und Schneider im Westen. Im Rheinland und Teilen Schwabens ist Becker der dominante Name, während in Schwaben zusätzlich Zimmermann eine signifikante Position besitzt. Ebenfalls zeigt die Abbildung, dass der Name Richter richtig eine dominante Rolle im Osten zugewiesen wurde. Somit wird durch diese Verteilungen die im Modell vorgegebenen Namensschwerpunkte bestätigt und die Simulation bildet die intendierten Strukturen erfolgreich ab.




Abb. 5: Die in der Simulation verwendeten dominanten Namen sind regionsspezifisch gebunden.

Aus **Abb. 5** wird der dominante Name pro Bundesland ersichtlich. Um die Simulation so realistisch wie möglich zu gestalten, wurden die Namensvektoren mit den realen absoluten Häufigkeiten der Nachnamen² normiert. Da Müller bundesweit am häufigsten

² Vgl. <https://www.namenforschung.net/dfd/woerterbuch/liste/> (Zugriff 31.03.2026)

auftaucht, wurde auch dessen Häufigkeit zur Normierung verwendet. Dies hat jedoch auch zur Folge, dass aus der **Abb. 6** eine Dominanz des Namens Müllers ersichtlich wird. Lediglich in Berlin und Brandenburg hat sich der dominante Name durchgesetzt. Für die anderen Bundesländer kann jedoch beobachtet werden, dass der in der Simulation verwendete dominante Name auch den dominanten Namen für das gesamte Bundesland bildet.

Beide Darstellungen verdeutlichen somit, dass die simulierten Nachnamenverteilungen sowohl eindeutige regionale Schwerpunkte aber auch überregionale Muster bilden. Die Kombination aus regional typischen und ubiquitär verbreiteten Namen entspricht einer realistischen Struktur der Simulation und bildet somit eine geeignete Grundlage für die anschließende quantitative Analyse.

Dominanter Nachname pro Bundesland




Abb. 6: Bei einer Darstellung der dominanten Nachnamen pro Bundesland treten auch ubiquitäre Namen wie Müller auf.

6.2 Regionale Unterschiede: Jensen-Shannon-Divergenz und Gini-Koeffizient

Für die Analyse regionaler Unterschiede in den simulierten Nachnamenverteilungen werden zwei komplementäre Maße verwendet: die Jensen-Shannon-Divergenz zur Quantifizierung von Unterschieden zwischen Regionen sowie der Gini-Koeffizient zur Beschreibung der inneren Konzentration der jeweiligen Verteilungen. Während die Divergenz den Abstand zwischen regionalen Profilen misst, gibt der Gini-Koeffizient Aufschlüsse, über die Namenskonzentration innerhalb einer Region,

Die Jensen-Shannon-Divergenz basiert auf den relativen Nachnamenverteilungen und bestimmt deren Ähnlichkeit. Niedrige Werte weisen ähnliche Verteilungen auf, wohingegen hohe Werte deutliche Unterschiede anzeigen. Da Nachnamen als Wahrscheinlichkeitsvektoren modelliert werden können, ist dieses Maß für die quantitative Analyse onomastischer Daten besonders geeignet. Beide Maße werden in der quantitativen Linguistik häufig eingesetzt, da sprachliche Einheiten als Verteilungen modelliert werden können.




Abb. 7: Die Heatmap der Jensen-Shannon-Divergenz veranschaulicht wie ähnlich die Verteilungen in den einzelnen Regionen zueinander sind. Je höher der Wert desto unterschiedlicher sind die Verteilungen.

Die Ergebnisse der aggregierten Regionenmatrix (vgl. **Abb. 7**) zeigen zunächst, dass die Werte innerhalb einer Region auf der Diagonale durchgängig niedrig sind. Dies deutet

auf eine hohe interne Kohärenz der Regionen hin. Gleichzeitig treten zwischen den Regionen klare Unterschiede auf. Besonders hohe Divergenzen zeigen sich zwischen West und Rheinland sowie zwischen West und Schwaben, während wiederum Rheinland und Schwaben mit 0.103 vergleichsweise ähnlich sind. Insgesamt wird ein differenziertes Muster aus klar abgegrenzten Regionen und partiellen Übergängen ersichtlich.

Zusätzlich dazu beschreibt der Gini-Koeffizient (vgl. **Abb. 8**) die Konzentration der Nachnamen innerhalb einer Region. Hohe Werte implizieren, dass wenige Namen dominieren, während niedrige Werte auf eine gleichmäßigere Verteilung verweisen. Die höchsten Konzentrationen weisen West (0.443) und Nord (0.415) auf, wohingegen Schwaben (0.321), Bayern (0.345) und Ost (0.343) deutlich gleichmäßigere Verteilungen zeigen. Rheinland liegt mit 0.394 im Mittelfeld.

Das Zusammenspiel beider Maße verdeutlicht, dass regionale Unterschiede auf zwei Ebenen bestehen. in der Zusammensetzung der Namensverteilungen sowie in deren innerer Konzentration. Die Ergebnisse zeigen somit, dass die simulierten Regionen sowohl intern konsistent als auch untereinander klar differenziert sind und sich für die weitere Analyse regionaler Muster eignen.

Lorenzkurven der Nachnamenverteilungen nach Region




Abb. 8: Zu sehen sind die Lorenzkurven für die Gini-Koeffizienten der einzelnen Regionen. Je näher die bunten Linie an der oberen gestrichelten Linie liegen, desto weniger Namen dominieren innerhalb einer Region.

7. Unsupervised Learning: Clusteranalyse

7.1 K-Means-Clustering

Zur Bestimmung struktureller Eigenschaften der simulierten Namensverteilungen wird zunächst ein Clustering-Verfahren auf Ortsebene durchgeführt. Dabei ist es das Ziel zu untersuchen, ob sich die Orte allein auf Grundlage ihrer Namensprofile in Gruppen einteilen lassen, die den zugrunde gelegten Makroregionen möglichst ähnlich sind. Dabei wird bewusst auf die Verwendung von Regionslabels verzichtet, damit ausschließlich eine datengetriebene Gruppierung erfolgt.

Folglich wird mit einer festgelegten Anzahl von sechs Clustern im *k-Means*-Algorithmus gearbeitet. Dabei wird jeder Ort von einem Vektor relativer Namenshäufigkeiten repräsentiert, sodass die Ähnlichkeit zwischen Orten anhand ihrer Namensverteilungen bestimmt wird. Die daraus entstehenden Cluster werden anschließend visualisiert, um so die geographische Ausdehnung der Cluster zu verdeutlichen




Abb. 9: Dargestellt ist das *k-Means*-Clustering auf Ortsebene. Es wurden $n = 6$ Cluster vorgegeben. Dabei fällt ins Auge, dass Lübeck Bayern zugeordnet wird. Daher kommt es zu einer Überlappung der Cluster.

Aus **Abb. 9** geht hervor, dass sich auf Ortsebene größtenteils eine klare Struktur erkennen lässt. Viele Orte derselben Region werden demselben Cluster zugeordnet, was nahelegt, dass die Namensverteilungen innerhalb der Regionen hinreichend homogen sind. Besonders auffällig wird dies für Schwaben, Rheinland oder West, in den die Zuordnung nahezu konsistent erfolgt. Dabei bilden diese Cluster klar abgegrenzte geographische Bereiche, die gut mit den simulierten Regionen in Einklang gebracht werden können.

Nichtsdestoweniger zeigen sich auch Abweichungen innerhalb der Cluster. Insbesondere im Norden tritt eine stärkere Streuung auf, sodass einzelne Instanzen verschiedenen Schwerpunkten zugeordnet werden. Dies legt den Schluss nah, dass die Namensverteilungen in dieser Region heterogener ausfallen oder stärkere Übergänge zu benachbarten Regionen bestehen. Diese Effekte können auch in realen Räumen auftreten und sprechen für die Realitätsnähe der Simulation.

Ergänzend zu einer Analyse auf Ortsebene wurde auch die aggregierte Ebene betrachtet, indem die Zuordnung von Bundesländern zu Clustern untersucht wird (**Abb. 10**). Hierbei zeigt sich, dass viele Bundesländer konsistent zu einzelnen Clustern zugeordnet werden können. So können die simulierten Makroregionen zu größten Teilen reproduziert werden, was eine stabile regionale Struktur impliziert.

Clustering der Bundesländer basierend auf Namensverteilungen




Abb. 10: Dargestellt ist das *k-Means*-Clustering auf Regionalebene. Es wurden $n = 6$ Cluster vorgegeben. Baden-Württemberg bildet ein Cluster mit Rheinland-Pfalz und dem Saarland. Der Osten zerfällt in zwei einzelne Cluster.

Die parallele Betrachtung von Orts- und Regionalebene erlaubt eine differenzierte Bewertung der Clustering-Ergebnisse. Während auf Ortsebene detaillierte Differenzen sichtbar werden, zeigt die aggregierte Analyse die übergeordneten Strukturen. So ergibt sich ein konsistentes Bild: Die simulierten Namensverteilungen enthalten klare regionale Muster, die durch das Clustering weitestgehend korrekt rekonstruiert werden können. Parallel wird an einzelnen Regionen, insbesondere Nord, eine höhere interne Variabilität deutlich, was zu partiellen Abweichungen von der idealen Clusterstruktur führt.

Dennoch bestätigen diese Ergebnisse, dass Clustering ein geeignetes Verfahren ist, um die grundlegende Struktur der Daten zu beleuchten. Gleichzeitig wird deutlich, dass die Übereinstimmung zwischen Clustern und realen Regionen nicht perfekt, sondern durch Übergänge und Überlappung geprägt ist. Dies bildet die Grundlage für weiterführende Analysen in den folgenden Abschnitten.

7.2 Bestimmung der optimalen Clusterzahl

Da k-Means im Voraus die Information benötigt, wie vielen Clustern es die Instanzen zuordnen soll, ist es im Vorfeld notwendig für die bestmögliche Analyse die optimale Clusterzahl zu bestimmen und so die zugrunde liegende Datenstruktur am besten abbildet. Zur Beantwortung dieser Frage wird der Silhouettenkoeffizient herangezogen. Dabei misst der Silhouettenkoeffizient, wie gut ein Datenpunkt seinem eigenen Cluster zugeordnet werden kann im Vergleich zu anderen Clustern. Werte um 1 deuten auf eine klare Zuweisung, Werte um 0 auf Überlappung und Werte gegen -1 auf eine falsche Zuordnung hin. Der durchschnittliche Silhouettenkoeffizient über alle Datenpunkte liefert somit ein globales Maß für die Qualität der Clusterstruktur.

In der vorliegenden Analyse kann gezeigt werden, dass der Silhouettenkoeffizient mit zunehmender Clusteranzahl zunächst ansteigt und bei $k = 6$ mit einem Wert von 0.344 sein Maximum erreicht (vgl. **Abb. 11**). Bei kleineren Clusterzahlen ist der Silhouettenkoeffizient geringer, da unterschiedliche Regionen zusammengefasst werden. Für größere Werte von k nimmt die Qualität jedoch wieder ab, da die Cluster zunehmend fragmentiert werden und dadurch die interne Kohärenz sinkt.

Besonders aufschlussreich ist, dass das Maximum bei $k = 6$ auftritt, was exakt der Anzahl der simulierten Regionen entspricht. Dies bestätigt, dass die zugrunde liegende Datenstruktur tatsächlich sechs klar unterscheidbare Gruppen enthält. Der Wert von 0.344 zeigt, dass die Cluster zwar deutlich erkennbar, aber nicht vollständig isoliert auftreten. Dies ist mit den in Kap. 7.1 gefundenen Überlappungen zwischen den Regionen.

Insgesamt kann durch die Silhouettenanalyse die Wahl von sechs Makroregionen verteidigt werden. Somit liefert die sie eine wichtige methodische Grundlage für weitere Analysen und bestätigt die Aussagekraft der Clustering-Ergebnisse.




Abb. 11: Durch den Silhouette-Score kann die ideale Anzahl Cluster k bestimmt werden. Bei einer Anzahl von sechs Clustern ist der Silhouettenkoeffizient am höchsten.

7.3 Vergleich mit simulierten Regionen

Für eine Bewertung der in Kap. 7.1 identifizierten Cluster wird ein direkter Vergleich mit den zugrunde liegenden Regionen durchgeführt. Dafür wird eine Kreuztabelle erstellt, die Aufschluss darüber gibt, welcher Anteil der Orte einer Region einem Cluster zugeordnet sind (vgl. **Abb. 12**).

Es kann festgestellt werden, dass die Ergebnisse eine insgesamt sehr hohe Übereinstimmung von 89,93% Übereinstimmung zwischen Clustern und Regionen zeigen. Bis auf die Region Nord konnten alle Regionen vollständig einem Cluster zugeordnet werden. Dies weist auf eine geringere Homogenität und stärkere Übergangseffekte im Norden hin. Die Region Nord nimmt damit eine Sonderrolle ein und bestätigt die bereits in den vorherigen Analysen identifizierte Variabilität.

Übereinstimmung von realer Region und KMeans-Cluster




Abb. 12: Die Heatmap gibt Auskunft darüber, wie gut die vorgegebenen Regionen und gefundenen Cluster übereinstimmen. Bis auf Nord konnten alle Cluster deckungsgleich gefunden werden. Bei acht Städten pro Region zeigt diese Grafik, dass zwei Städte des Nordens fälschlich zugeordnet wurden.

Insgesamt wird durch den Vergleich deutlich, dass die Clusterstruktur in hohem Maße mit den simulierten Regionen übereinstimmt, jedoch nicht vollständig deckungsgleich ist. Diese Abweichungen sind dabei nicht als Schwäche des Verfahrens, sondern als Ausdruck der komplexen und überlappenden Struktur zu sehen. Durch das Clustering können somit die wesentlichen regionalen Muster abgebildet werden, ohne diese künstlich zu vereinfachen.

7.4 DBSCAN

Parallel zum partitionierenden *k*-Means-Algorithmus wurde mit DBSCAN (*Density-Based Spatial Clustering of Applications*) ein dichtebasiertes Clustering-Verfahren verwendet, das untersuchen sollte, ob sich die simulierten Namensräume auch als natürliche Verdichtungen im Merkmalsraum rekonstruieren lassen. Im Unterschied zu *k*-

Means setzt DBSCAN keine feste Anzahl von Clustern voraus, sondern für jede Instanz zählt der Algorithmus, wie viele Nachbarinstanzen es mit einem Abstand ε es zu ihr gibt. Diese Gegend wird als ε -Nachbarschaft bezeichnet. Durch den Parameter *min_samples* wird festgelegt, wie viele Nachbarn ein Datenpunkt haben muss, damit diese Ansammlung als Kerninstanz gesehen wird. Punkte die nicht zu einer Kerninstanz gehören, werden vom Algorithmus als Anomalie oder Rauschen behandelt (Géron 2023, 313). Somit kann DBSCAN eigenständig dichtebasierte Räume erkennen.

Um die optimalen Parameter ε und *min_samples* zu bestimmen, wurde eine systematische *Grid Search* über die Wertebereiche der beiden Parameter durchgeführt. Anschließend wurden die gefundenen Dichteräume mit Hilfe des *Adjusted Rand Index* (ARI) sowie der *Normalised Mutual Information* (NMI) mit den zugrunde liegenden Regionen verglichen. Ebenfalls wurden die Anzahl der identifizierten Cluster sowie der Anteil an als Rauschen klassifizierten Punkten berücksichtigt, um so die bestmögliche Analyse zu ermöglichen. Dabei hat sich als optimale Parameterkombination $\varepsilon = 1.4$ und *min_samples* = 3 erwiesen (vgl. **Abb. 13**). Bei dieser Einstellung konnten sechs Cluster gefunden werden, was der Anzahl der gegebenen Makroregionen entspricht. Hierbei konnte eine Übereinstimmung mit einem ARI von 0.842 und einer NMI von 0.924 beobachtet werden, was für eine hohe Überlappung spricht. Allerdings wurde auch ein Rauschen von 12.5% festgestellt, was bedeutet, dass ein Teil der Beobachtungen nicht eindeutig einer Clusterstruktur zugeordnet werden kann.

DBSCAN-basierte Cluster regionaler Namensverteilungen ($\text{eps} = 1.40$, $\text{min_samples} = 3$)




Abb. 13: Durch DBSCAN selbstständig gefundene Schwerpunkträume.

Dieses Ergebnis führt einen zentralen Unterschied zwischen partitionierenden und dichte-basierten Verfahren vor Augen: Während *k-Means* eine vollständige Zuordnung aller Orte erzwingt, werden durch DBSCAN nur jene Regionen identifiziert, die eine hinreichend hohe Dichte im Merkmalsraum aufweisen. Die hohe Übereinstimmung der identifizierten Cluster mit den simulierten Regionen zeigt, dass die simulierten Namensräume klar ausgeprägte Zentren besitzen. Dennoch weist der gleichzeitig Anteil an Rauschen darauf hin, dass nicht alle Orte Teil solcher Kerne sind, sondern teilweise Übergangsbereiche oder weniger charakteristische Namensprofile aufweisen.

Es lässt sich konstatieren, dass DBSCAN die Existenz regionaler Strukturen bestätigt, jedoch auch ersichtlich wird, dass diese Strukturen nicht flächendeckend homogen sind. Vielmehr besteht ein Dichteraum aus einer Kombination aus Kernregionen und weniger zuordbaren Randbereichen. Diese Eigenschaft wäre bei ausschließlicher Verwendung partitionierender Verfahren nicht ersichtlich geworden.

8. Supervised Learning: SVM-Klassifikation

Während in den vorangegangenen Kapiteln unüberwachte Lernverfahren wie k-Means und DBSCAN verwendet wurden, um inhärente Strukturen in den Namensverteilungen zu identifizieren, verfolgt dieses Kapitel einen komplementären Ansatz. Dabei ist es das Ziel, die obig beobachteten Muster mittels eines überwachten Lernverfahrens explizit zu überprüfen. Dafür wird ein Support Vector Machine (SVM)-Modell eingesetzt, das auf Basis bekannter Regionalzugehörigkeiten trainiert wird.

8.1 Methodik und Modellansatz

Das zentrale Unterscheidungsmerkmal zu den Clustering-Verfahren besteht darin, dass bei der SVM-Klassifikation eine Zielvariable – hier die Zugehörigkeit eines Ortes zu einer der sechs vordefinierten Makroregionen – bereits vorgegeben ist. Wie bereits erwähnt identifizieren k-Means und DBSCAN eigenständig Cluster im Datenraum, wohingegen SVM versucht, eine Entscheidungsfunktion zu erlernen, die diese Instanzen möglichst trennscharf voneinander abgrenzt. Daher kann die SVM als ein Validierungsinstrument der zuvor entdeckten Strukturen verstanden werden.

Als Input dienen erneut die relativen Nachnamenhäufigkeiten pro Ort (`df_rel`), die bereits im Rahmen der Clustering-Analyse verwendet wurden. Diese Orte werden durch Vektoren repräsentiert, die die Verteilung der Nachnamen abbilden. Hierbei bilden die Vektoren den Merkmalsraum, in dem die Klassifikation erfolgt. Die Zielvariable wird aus den bekannten Regionen der Orte abgeleitet, sodass jedem Datenpunkt ein eindeutiges Label zugeordnet werden kann.

Für die Modellierung wird eine SVM mit radialer Basisfunktion (RBF-Kernel) verwendet. Der Begriff „Kernel“ bezeichnet dabei eine mathematische Funktion, die es ermöglicht, die Daten in einen höherdimensionalen Raum abzubilden, ohne dass diese Transformation explizit berechnet werden muss. Eben dadurch erlaubt das „Kernel-Trick-Verfahren“ auch komplexe, nichtlinear trennbare Strukturen effizient zu modellieren (MURPHY 2012, 480).

Die verwendete radiale Basisfunktion ist eine spezielle Form eines derartigen Kernels. Sie beruht auf der Idee, dass Datenpunkte, die sich im Merkmalsraum ähnlich sind, auch in einem transformierten Raum nah beieinander liegen. Vereinfacht formuliert muss die Funktion die „Ähnlichkeit“ zwischen zwei Orten anhand ihrer Namensverteilungen: Je ähnlicher die Verteilungen, desto stärker ist ihr Einfluss auf die

Klassifikationsentscheidung. Dadurch treten flexible, nichtlineare Entscheidungsgrenzen zu Tage, die sich gut an die Struktur der Daten anpassen können (MURPHY 2012, 505). Insgesamt ergänzt sie SVM-Klassifikation die zuvor eingesetzten unüberwachten Verfahren, indem sie nicht nur Strukturen sichtbar macht, sondern deren Vorhersehbarkeit explizit testet. Sie bildet somit einen wichtigen Schritt in Richtung einer umfassenden Evaluation der Modellannahmen und der Aussagekraft der simulierten Daten.

8.2 Training und Klassifikationsergebnisse

Für die SVM-Klassifikation wird der Datensatz zunächst in Trainings- und Testdaten aufgeteilt. Dabei werden 70% der Beobachtungen für das Trainieren des Modells verwendet, während die verbleibenden 30% als unabhängige Testmenge fungieren. Um sicherzustellen, dass alle Regionen in den beiden Teilmengen repräsentativ repräsentiert sind, erfolgt die Aufteilung stratifiziert. Ebenfalls ist die Festlegung durch Zuweisung eines Zufallseeds vollständig reproduzierbar, sodass über mehrere Durchläufe mit identischen Trainings- und Testmengen gearbeitet werden kann.

Das SVM-Modell wird anschließend auf Basis der Trainingsdaten geschätzt. Dabei ist es das Ziel, eine Entscheidungsfunktion zu erlernen, die die Orte anhand der Namensverteilungen möglichst eindeutig einer der sechs Regionen zuordnet. Das Modell wird schließlich nach Abschluss des Trainings auf die Testdaten angewendet, um für jeden Ort eine vorhergesagte Region zu bestimmen. Dies erlaubt eine Aussage über die Generalisierungsfähigkeit des Modells, als sein Vermögen, auch bisher unbekannte Daten zutreffend zu klassifizieren.

Die Ergebnisse der Klassifikation werden in Form einer Karte in **Abb. 14** dargestellt. Jeder Ort wird dabei entsprechend seiner vorhergesagten Region eingefärbt, wobei zusätzlich zwischen korrekt und falsch vorhergesagten Regionen unterschieden wird. Somit kann dieses Modell für eine intuitive Einschätzung der Modellgüte herangezogen werden und ermöglicht des Weiteren auch eine räumliche Einordnung möglicher Fehlklassifikationen.

SVM-Klassifikation der Regionen




Abb. 14: Klassifizierung der Instanzen via einer SVM. Da nur 30% Testdaten der Population entnommen wurden, sind nur 15 Punkte verzeichnet. Davon konnten 14 richtig zugeordnet werden.

Die Klassifikation erreicht eine Gesamtgenauigkeit von 93,3%, was bedeutet, dass von 15 Testbeobachtungen 14 korrekt zugeordnet werden. Dies impliziert eine hohe Trennschärfe der zugrunde liegenden Namensverteilungen. Fünf von sechs Regionen werden richtig klassifiziert, was auf eine klare Abgrenzung dieser Regionen im Merkmalsraum hindeutet.

Auffällig jedoch ist, dass im Norden eine geringere Trefferquote erzielt wird. Dabei wird einer von zwei Orten falsch klassifiziert, was durch einen Recall-Wert von 0.50 widerspiegelt wird. Diese Fehlklassifikation deckt sich mit den zuvor beobachteten Mustern aus der Clustering-Analyse und zeigt auf, dass die Namensverteilungen in dieser Region weniger eindeutig zu unterscheiden sind. Die Region Ost wird hingegen trotz leicht geringerer Präzision korrekt erkannt, was eine stabile, aber teilweise leicht überlappende Struktur impliziert.

Insgesamt zeigen die Klassifikationsergebnisse, dass die obig identifizierten Strukturen nicht nur existieren, sondern auch in hohem Maße vorhersagbar sind. Damit bestätigt die SVM die Aussagekraft der simulierten Namensverteilungen als Grundlage für eine regionale Differenzierung und liefert eine solide Basis für die anschließende Evaluation der Modellleistung.

8.3 Evaluation und Fehleranalyse

Zur detaillierten Bewertung der Klassifikation wird ergänzend die Confusion-Matrix herangezogen (vgl. **Abb. 15**). Diese stellt die tatsächlichen gegenüber den vorhergesagten Klassen dar und ermöglicht eine präzise Identifikation von Fehlzuordnungen.

Confusion Matrix der SVM-Klassifikation

Tatsächliche Region	Bayern	2	0	0	0	0	0
	Nord	0	1	1	0	0	0
	Ost	0	0	3	0	0	0
	Rheinland	0	0	0	3	0	0
	Schwaben	0	0	0	0	3	0
	West	0	0	0	0	0	2
		Bayern	Nord	Ost	Rheinland	Schwaben	West
		Vorhergesagte Region					

Accuracy = 0.933

Abb. 16: Confusion-Matrix der SVM-Klassifikation. Die dargestellte Confusion-Matrix basiert auf den finalen Klassifikationsergebnissen.

Dabei wird aus der Matrix ersichtlich, dass die größte Mehrheit der Beobachtungen richtig klassifiziert wird. Bayern, Rheinland, Schwaben, West und Ost weisen alle ausschließlich korrekte Beobachtungen auf. Dies unterstreicht die klare Differenzierbarkeit der Regionen im Merkmalsraum.

Lediglich im Norden kommt es zu Fehlklassifikationen. Ein Ort wird fälschlicherweise der Region Ost zugeordnet. Diese Ergebnis bestätigt die bereits in den vorherigen Analysen beobachtete strukturelle Nähe zwischen nord- und ostdeutschen

Namensverteilungen. Die Fehlzuordnung ist somit nicht als zufälliger Fehler, sondern als Ausdruck überlappender Verteilungsstrukturen zu interpretieren.

Insgesamt verdeutlicht die Confusion-Matrix, dass die Klassifikationsfehler nicht zufällig verteilt sind, sondern auf spezifische Ähnlichkeiten zwischen einzelnen Regionen zurückzuführen sind. Dies spricht für die inhaltliche Konsistenz des Modells und bestätigt zugleich die in den Clustering- und Distanzanalysen identifizierten Muster.

9. Diskussion methodischer Grenzen

Die vorliegende Analyse zeigt, dass regionale Namensverteilungen mithilfe probabilistischer Modelle tiefgehend untersuchen lassen. Allerdings erfordert ein solcher modellbasierter Ansatz eine kritische Reflexion der Annahmen und Grenzen. Insbesondere die Verwendung simulierter Daten, die Parametrisierung der Verteilungen sowie die Interpretation der Ergebnisse müssen in Hinblick auf ihre Aussagekraft und Übertragbarkeit eingeordnet werden.

9.1 Modellannahmen und Realität

Da das entwickelte Modell vollständig auf synthetisch erzeugten Daten beruht, stellt es somit eine bewusste Abstraktion von realen onomastischen Verhältnissen dar. Durch die Dirichlet-Verteilung können zwar regionale Wahrscheinlichkeitsstrukturen flexibel konstruiert werden, jedoch bilden diese keine historischen, sozialen oder migrationsbedingten Prozesse ab, die reale Namensverteilungen maßgeblich prägen.

Zudem wurde sowohl die Anzahl der betrachteten Nachnamen als auch die Größe der simulierten Bevölkerung bewusst stark begrenzt. Reale Namensräume weisen eine weit größere Diversität auf, sodass eine Auswahl dominanter Namen stets zu einer Vereinfachung der tatsächlichen Komplexität führt.

Das Modell ist somit nicht als realitätsgetreue Rekonstruktion zu verstehen, sondern als ein idealisiertes System, das sich an wahren Gegebenheiten orientiert, und zentrale Mechanismen isoliert und analysierbar macht. Die Stärke dieses Ansatzes liegt folglich weniger in der direkten empirischen Abbildung als in der strukturellen Nachvollziehbarkeit der erzeugten Muster.

Alternativ wäre es prinzipiell möglich gewesen, reale Namensverteilungen auf Basis einer Auswertung von Telefonbuchdaten der einzelnen Städte zu rekonstruieren, oder

durch das sog. *Crawlen* Informationen aus den digitalen Telefonbüchern zu extrahieren. Zwar würde dies eine Abbildung realer Strukturen ermöglichen, ist jedoch mit erheblichen methodischen und Praktischen Herausforderungen verbunden. Neben datenschutzrechtlichen Einschränkungen erfordern insbesondere die systematische Erhebung, Bereinigung und Aggregation einen erheblichen Aufwand. Daher wurde im Rahmen dieser Arbeit auf ein solches Vorgehen verzichtet.

9.2 Sensitivität gegenüber α -Parametern

Die Wahl der Dirichlet-Parameter α_i bestimmt maßgeblich die Form der regionalen Namensverteilungen. Zwar beruhen diese Parameter auf onomastisch begründeten Annahmen, bleiben jedoch letztlich modellgetrieben und damit in gewissem Maße subjektiv. Insbesondere die Gewichtung dominanter Namen sowie die Skalierung der Parameter beeinflussen unmittelbar die resultierenden Verteilungen und damit sämtliche nachgelagerten Analysen.

Daher folgt eine deutliche Sensitivität des Modells gegenüber diesen Parametern: Bereits kleine Anpassen führen zu anderen Verteilungen und somit auch zu veränderten Clusterstrukturen, Divergenzen oder Klassifikationsergebnissen. Die Ergebnisse dürfen somit nicht unabhängig von den getroffenen Annahmen interpretiert werden, sondern spiegeln diese eher wider.

Gleichzeitig bietet sich jedoch dadurch auch die Möglichkeit, verschiedene Szenarien systematisch zu analysieren. Die Parametrisierung ist somit keine bloße Einschränkung, sondern auch ein methodisches Instrument zu Exploration hypothetischer Verteilungen. Voraussetzung hierfür ist jedoch ein transparenter Umgang mit den Parametern und eine theoretisch fundierte Herleitung der gewählten Parameter.

9.3 Onomastische Interpretation

Trotz der genannten Einschränkungen ermöglicht das Modell eine inhaltlich fundierte Einordnung im Rahmen onomastischer Fragestellungen. Die Ergebnisse verdeutlichen, dass bereits vergleichsweise einfache, regional gewichtete Namensverteilungen ausreichen, um klar unterscheidbare Strukturen zu erzeugen. Regionale Konzentrationen von Familiennamen stellen somit ein tragfähiges analytisches Signal dar.

Die hohe Klassifikationsgenauigkeit sowie die stabilen Clusterstrukturen implizieren, dass die modellierten Differenzen systematisch sind. Besonders relevant ist, dass beobachtete Fehlklassifikationen mit zuvor identifizierten Ähnlichkeiten zwischen Regionen übereinstimmen. Dies zeigt, dass das Modell reale Tendenzen zumindest auf struktureller Ebene approximiert.

Parallel ist die Interpretation bewusst zurückhaltend zu formulieren: Es handelt sich eben nicht um eine empirische Rekonstruktion realer Namensverteilungen, sondern um eine theoretische Exploration ihrer möglichen Struktur. Der Beitrag dieser Arbeit liegt somit in der Verbindung onomastischer Fragestellungen mit probabilistischen Modellierungsansätzen sowie einer korpusähnlichen Betrachtung von Namensverteilungen. Insgesamt zeigt sich, dass der hiesige Ansatz geeignet ist, Mechanismen regionaler Differenzierung sichtbar zu machen, ohne den Anspruch zu erheben, die komplexe Realität vollständig abzubilden.

Fazit

Ziel der vorliegenden Arbeit war es zu untersuchen, inwieweit regionale Strukturen in der Verteilung von Berufsnamen mithilfe quantitativer und datengetriebener Verfahren modelliert und analysiert werden können. Dazu wurde auf Grundlage literaturgestützter Annahmen ein probabilistisches Modell entwickelt, das strukturierte Namensverteilungen erzeugt.

Die Ergebnisse verdeutlichen, dass bereits auf deskriptiver Ebene regionale Unterschiede ersichtlich werden. Sowohl die Analyse dominanter Namen als auch die Betrachtung relativer Häufigkeiten verdeutlichen, dass bestimmte Namen in einzelnen Regionen systematisch häufiger auftreten. Diese Muster konnten durch die Entropieanalyse weiter gestützt werden, die Unterschiede in der Diversität der Namensverteilungen sichtbar macht.

Auch weitere vergleichende Verfahren bestätigen diese Befunde. Die Jensen-Shannon-Divergenz weist eindeutige Unterschiede zwischen den Regionen nach, während die Clusteranalyse stabile Gruppierungen identifiziert, die sich weitgehend mit den festgelegten Makroregionen decken. Die Ergebnisse implizieren, dass die simulierten Namensräume konsistente Strukturen aufweisen, die sich algorithmisch rekonstruieren lassen.

Deutlich wird dies insbesondere bei der Klassifikationsanalyse: Die hohe Präzision des SVM-Modells zeigt, dass die Regionen auf Basis ihrer Namensverteilungen in hohem Maße unterscheidbar sind. Die geringen Fehlklassifikationen, insbesondere im Norden, zeigen die Existenz von Übergangsräumen und strukturellen Ähnlichkeiten zwischen einzelnen Regionen.

Vor diesem Hintergrund können die eingangs aufgestellten Thesen weitestgehend bestätigt werden. Es konnte erstens gezeigt werden, dass regionale Unterschiede in Namensverteilungen auch unter vereinfachten Modellannahmen statistisch identifizierbar sind und sich konsistent über mehrere Analyseverfahren hinweg nachweisen lassen. Zweitens wurde deutlich, dass Regionen mit ähnlichen Namensprofilen Cluster bilden, die strukturelle Ähnlichkeiten zu historisch gewachsenen Namensräumen aufweisen können. Einschränkend muss jedoch betont werden, dass diese Strukturen im Rahmen der Simulation durch Parametrisierung vorgegeben sind und daher nicht vollständig unabhängig entstehen.

Dennoch verdeutlicht diese Arbeit somit das Potential quantitativer Methoden für die onomastische Forschung, zeigt jedoch zugleich deren Grenzen auf. Die verwendeten Daten basieren auf modellierten Verteilungen und können reale Namensräume nur näherungsweise abbilden. Insbesondere die Festlegung der α -Parameter stellt einen zentralen Eingriff dar, der die Ergebnisse maßgeblich beeinflusst.

Ein vielversprechender Ansatz für zukünftige Forschung könnte somit in der Anwendung der entwickelten Methoden auf reale Datensätze, wie z.B. im Bereich der Dialektologie liegen. Darüber hinaus könnten komplexere Modelle entwickelt werden, die noch präziser Migration, soziale Dynamiken oder zeitliche Veränderungen berücksichtigen.

Insgesamt zeigt die Arbeit, dass Familiennamen nicht nur als sprachhistorische Artefakte, sondern als strukturierte Daten verstanden werden können, die sich mit quantitativen Verfahren systematisch analysieren lassen. Damit eröffnet sich ein erweitertes Verständnis onomastischer Fragestellungen an der Schnittstelle von Linguistik, Datenanalyse und *Digital Humanities*.

Anhang

A Tabellen

A.1 Historisch-regionale Namensverteilungen

Tabelle 1: Normierungsfaktoren der einzelnen Nachnamen.

Name	Abs. Häufigkeit	Normierungsfaktor
Müller	256003	1
Schmidt	190854	0,746
Schneider	115749	0,452
Fischer	97658	0,381
Meyer	83586	0,327
Weber	86061	0,336
Schulz	73736	0,288
Wagner	79732	0,311
Becker	74009	0,289
Zimmermann	42872	0,167
Schäfer	61591	0,241
Koch	59927	0,234
Schröder	50648	0,198
Richter	59950	0,234
Bauer	58903	0,230

Tabelle 2: α -Parameter der Namen für die jeweiligen Regionen.

	Nord	Ost	West	Rheinland	Bayern	Schwaben
Müller	50,00	50,00	50,00	50,00	50,00	50,00
Schmidt	111,83	37,28	37,28	37,28	37,28	37,28
Schneider	22,61	22,61	113,03	22,61	22,61	22,61
Fischer	19,07	19,07	19,07	19,07	19,07	19,07
Meyer	16,33	16,33	16,33	16,33	48,98	16,33
Weber	16,81	16,81	50,43	16,81	16,81	16,81
Schulz	14,40	43,20	14,40	14,40	14,40	14,40
Wagner	15,57	15,57	15,57	15,57	15,57	15,57
Becker	14,45	14,45	14,45	72,27	14,45	43,36
Zimmermann	8,37	8,37	8,37	8,37	8,37	41,87
Schäfer	12,03	12,03	12,03	36,09	12,03	12,03
Koch	11,70	11,70	11,70	11,70	11,70	11,70
Schröder	49,46	9,89	9,89	9,89	9,89	9,89
Richter	11,71	58,54	11,71	11,71	11,71	11,71
Bauer	11,50	11,50	11,50	11,50	57,52	11,50

A.2 Variation der Orts-Homogenität β

Tabelle 3: Ergebnisse verschiedener Parameter bei einer Variation von β .

β	mean_silhouette	std_silhouette	mean_js_divergence	std_js_divergence
20	0.200	0.027	0.024	0.009
50	0.322	0.031	0.136	0.008
100	0.456	0.031	0.108	0.007

A.3 Variation der Namensdimension κ

Tabelle 4: Ergebnisse verschiedener Parameter bei einer Variation von κ .

κ	mean_silhouette	std_silhouette	mean_js_divergence	std_js_divergence
15	0.266	0.028	0.075	0.005
30	0.109	0.019	0.055	0.005
45	0.060	0.014	0.053	0.004

B Python-Code für Reduzierbarkeit

erfolgt als separate PDF-Datei.

Literaturverzeichnis

- BAHLOW, Hans (2005): Deutsches Namenlexikon. Familien- und Vornamen nach Sinn und Ursprung erklärt
- CASEMIR, Kirstin (2009): Familiennamen aus Berufsbezeichnungen. Namengebung und Namenmotivation am Beispiel des Bäckergerwerbes. In: Hengst, Karlheinz/Krüger, Dietlind (eds.): Familiennamen im Deutschen, Band 1. Leipzig, 165–191.
- DRÄGER, Kathrin/Kunze, Konrad (2016): Westfalen im Deutschen Familiennamenatlas. In: Roelfs, Friedel (ed.): Bäuerliche Familiennamen in Westfalen. Münster, 21–44
- DRÄGER, Kathrin/Schmuck, Mirjam (2009): The German Surname Atlas Project– Computer-based surname geography. In: Proceedings of the 23rd ICOS. Toronto, 319–336.
- EICHLER, Ernst (Hrsg.): Namensforschung. Ein internationales Handbuch zur Onomastik, Band 1 & 2, Berlin 2008.
- FAHLBUSCH, Fabian et al.: Morphologie der Familiennamen, Berlin / Boston 2012.
- FAHRMAIR, Ludwig et al.: Statistik: Der Weg zur Datenanalyse, Heidelberg 2024.

- FARØ, Ken/Kürschner, SEBASTIAN (2007): Et databasemøde mellem Jensen og Müller: Om kontrastiv antroponomastisk metodik. In: Tijdschrift voor Skandinavistiek 28, 105–126.
- GELMAN, Andrew: Bayesian data analysis, 2nd ed., Boca Raton 2004.
- GÉRON, Aurélien: Praxiseinstieg Machine Learning mit Scikit-Learn, Keras und TensorFlow. Konzepte, Tools und Techniken für intelligente Systeme, 3. Aufl., Heidelberg 2023
- HEUSER, Rita/Damaris Nübling (2010): Von Angenendt über Derix, Janssen und Terlinden bis Elspaß. Niederrheinische Familiennamen im Rahmen des Deutschen Familiennamenatlases. In: Cornelissen, Georg/Eickmans, Heinz (eds.): Familiennamen an Niederrhein und Maas. Bottrop, 37–66.
- KLAUSMANN, Hubert (2007): Atlas der Familiennamen von Baden-Württemberg. Ostfildern.
– (2009): Atlas der Familiennamen von Bayern. Ostfildern.
- KUNZE, Konrad (2001): Zur Verbreitung der häufigsten deutschen Familiennamen. In: Eichhoff, Jürgen/Seibicke, Wilfried/Wolffsohn, Michael (Hrsg.): Name und Gesellschaft. Soziale und historische Aspekte der Namengebung und Namenentwicklung. Band 2. Mannheim [u.a.], S. 179-208.
- NÜBLING, Damaris / Kunze, Konrad (2023): Kleiner deutscher Familiennamenatlas. Entstehung, Gebrauch, Verbreitung und Bedeutung der Familiennamen, Berlin / Boston.
- NÜBLING, Damaris / Fahlbusch, Fabian / Heuser, Rita: Namen: Eine Einführung in die Onomastik, 2. Aufl., Tübingen 2015 (Narr Studienbücher)
- Seibicke, Wilfried (2008). Die Personennamen im Deutschen: eine Einführung. Berlin
- Zoder, Rudolf (1968): Familiennamen in Ostfalen. Hildesheim

Selbstständigkeitserklärung

Ich versichere hiermit, dass die Prüfungsleistung mit dem Thema

„Quantitative Onomastik - Eine Monte-Carlo-Studie zur Clusterstabilität und
parametrischen Robustheit regionaler Berufsamen“

von mir selbst und ohne jede unerlaubte Hilfe angefertigt wurde, dass sie weder an einer anderen Hochschule noch an dieser Universität als Prüfung vorgelegen hat und dass sie weder ganz noch in Auszügen veröffentlicht worden ist. Die Stellen der Prüfungsleistung – einschließlich Tabellen, Karten, Abbildungen usw. –, die anderen Werken dem Wortlaut oder dem Sinn nach entnommen sind, habe ich in jedem einzelnen Fall kenntlich gemacht.

Falls es sich bei der Prüfungsleistung um eine Bachelor- oder Masterarbeit handelt, bei der neben der dreifachen schriftlichen Ausfertigung die Einreichung einer digitalen Fassung zu erfolgen hat, versichere ich ferner, dass der Inhalt der Textdatei der digitalen Fassung identisch mit der eingereichten schriftlichen Ausfertigung ist.

Marc Wunderlich

Vor- und Nachname in Druckbuchstaben

Troisdorf, den 31.03.2026

